

Arrhythmia Prediction and Classification - تقرير تفصيلي للدكتور

الهدف من الشغل

Binary Prediction لتحديد Normal أو Arrhythmia، و Disease Classification لتصنيف نوع الاضطراب بعد تجميع الفئات النادرة بسبب قلة العينات. تم بناء إطار بحثي وعملي على UCI Arrhythmia Dataset يدعم مسارين:

البيانات المتاحة

البيانات	القيمة
Dataset	UCI Arrhythmia
عدد الحالات	452
عدد الخصائص	279
الفئات الأصلية	13
الفئات بعد التجميع	6
القيم المفقودة	408

ما تم تنفيذه


Stacking وإضافة Feature Tokenizer Transformer وتجربة SMOTE مع feature selection داخل cross-validation بدون data leakage. Logistic Regression و SVC و Random Forest و Extra Trees و XGBoost و LightGBM و CatBoost. كما تم بناء Soft Voting و Hybrid تم تجهيز البيانات داخل Pipeline، معالجة missing values، استخدام Stratified Cross-Validation، وتجربة

أفضل نتيجة Binary Prediction

Metric	Value
Best model	CatBoost Deep
Best threshold	0.490
Accuracy	84.51%
Balanced Accuracy	84.14%
F1-score	82.50%
ROC-AUC	89.44%

model	best_threshold	accuracy	balanced_accuracy	f1	roc_auc
CatBoost Deep	0.490	84.51%	84.14%	82.50%	89.44%
CatBoost Conservative	0.380	82.96%	83.24%	82.30%	89.43%
Advanced Stacking Hybrid	0.470	83.19%	83.07%	81.64%	88.75%
Advanced Soft Voting Hybrid	0.415	82.96%	83.01%	81.80%	88.80%
Extra Trees Tuned	0.490	81.64%	80.93%	78.33%	86.92%
Random Forest Tuned	0.445	79.87%	79.86%	78.38%	86.95%
LightGBM Regularized	0.525	79.65%	79.09%	76.53%	85.22%
SVC Tuned RBF	0.545	79.65%	78.71%	75.27%	84.88%


Binary Prediction - Balanced Accuracy



Disease Classification

بعض الفئات قليلة جدا. لذلك تم استخدام grouped multiclass classification حتى يكون التقييم أكثر منطقية بدل تدريب نموذج على فئات بها عينات نادرة جدا. الداتا الأصلية تحتوي على عدة فئات لاضطراب النظم، لكن

weighted_f1	macro_f1	balanced_accuracy	accuracy	model
72.33%	61.20%	63.75%	73.01%	CatBoost
73.12%	59.12%	59.90%	74.55%	Random Forest
71.43%	58.27%	57.73%	74.33%	LightGBM
70.81%	56.69%	55.02%	73.68%	XGBoost
63.88%	48.28%	48.31%	62.83%	Logistic Regression
61.35%	39.82%	37.28%	67.71%	Extra Trees



Feature Selection و SMOTE

feature selection داخل cross-validation. هذه التجربة لم تتفوق على CatBoost Deep، لذلك تم توثيقها كتجربة تحسين بحثية وليست النموذج النهائي. تمت تجربة SMOTE مع عدة طرق

roc_auc	f1	balanced_accuracy	accuracy	best_threshold	model
88.48%	81.34%	82.70%	82.74%	0.415	SMOTE + ExtraTrees-SFM + CatBoost
88.54%	80.19%	81.73%	81.86%	0.445	SMOTE + ExtraTrees-SFM + SMOTE Feature Voting Hybrid
87.47%	79.60%	81.50%	81.86%	0.475	SMOTE + ExtraTrees-SFM + Extra Trees
87.64%	78.04%	80.56%	81.19%	0.505	SMOTE + ExtraTrees-SFM + Random Forest
86.36%	78.64%	80.35%	80.53%	0.485	SMOTE + MI-96 + Random Forest
85.88%	78.45%	80.15%	80.31%	0.465	SMOTE + MI-96 + SMOTE Feature Voting Hybrid

Feature Tokenizer Transformer


Value	Metric
Feature Tokenizer Transformer	Model
79.12%	Accuracy
79.42%	Balanced Accuracy
78.65%	F1-score
79.01%	ROC-AUC

شكل الـ Output للمستخدم

CSV، ثم يتم فحص توافق الأعمدة، وبعدها يختار نوع المهمة. في النهاية يحصل على جدول نتائج واحتمالات وثقة النموذج ومستوى الخطورة، مع إمكانية تنزيل النتائج. في تطبيق Streamlit، المستخدم سيرفع

User Output	Section
رفع CSV وفحص عدد الصفوف والأعمدة والقيم المفقودة	Upload & Validate
اختيار Prediction أو Classification	Task Mode
predicted class, probability, confidence, risk level	Prediction Output
Accuracy, F1-score, ROC-AUC, Confusion Matrix وجود target عند وجود	Evaluation Output
تنزيل النتائج كملف CSV	Download

Streamlit Output Flow



الخلاصة

عدم توازن الفئات وصغر حجم الداتا. شكل الـ output النهائي واضح للمستخدم ويغطي upload, validation, prediction, evaluation, and download. أما Disease Classification فهي موجودة لكنها grouped بسبب ROC-AUC = 89.44% باستخدام CatBoost Deep. Accuracy = 84.51% أفضل نتيجة حالية في Binary Prediction هي