

تقرير تحديث مشروع التنبؤ بأمراض القلب

يوضح هذا التقرير ملاحظات الدكتور على الشغل، وكيف تم التعامل معها، وما الإضافات التي تم تنفيذها داخل النوتبوك والتقارير مع النتائج الأساسية.

1. ملاحظات الدكتور وكيف تم حلها

استخدام أكثر من Dataset لا يكفي كـ contribution.	الـ datasets وسيلة validation وليست الإضافة الأساسية. تمت إعادة صياغة الإسهام البحثي بحيث تصبح	Research Contribution Matrix داخل النوتبوك والتقرير. تمت إضافة
لازم يكون فيه technique أو framework جديد واضح.	SHAP و FT-Transformer و Feature Selection. Unified Explainable Hybrid Framework يجمع بين النماذج الهجينة تم تقديم الشغل كـ	تمت إضافة قسم Research Contribution Positioning.
المقارنة مع المنشور لا ينفع تكون كلام فقط.	Comparison With Published Work يضم أبحاث منشورة ونتائجنا. تمت إضافة جدول	وإضافته للنوتبوك والتقارير. تم إنشاء published_work_comparison.csv
المقارنة لازم توضح هل هي على نفس Dataset أم لا.	مباشرة أو غير مباشرة بسبب اختلاف الداتا أو البروتوكول. تمت إضافة عمود comparison_type لتوضيح هل المقارنة	تمت إضافة ملاحظة منهجية عن شروط المقارنة المباشرة.
لازم الشغل يبين إضافة بحثية فعلية.	Feature Selection، FT-Transformer، والتقييم القوي. تم ربط الإضافة البحثية بالهايبرد موديل، قابلية التفسير،	تم تحديث التقرير العربي والإنجليزي والنوتبوك المتنفذة.

2. الهدف من التحديث

الإسهام الأساسي أصبح إطارا موحدا قابلا للتفسير يجمع بين النماذج الهجينة، SHAP، Feature Selection و Feature Tokenizer Transformer. تم تعديل طريقة عرض المشروع بحيث لا يتم تقديم استخدام أكثر من Dataset كإسهام بحثي مستقل، بل يتم اعتباره وسيلة تحقق من ثبات الإطار المقترح.

3. الإضافات التي تمت على الشغل

- إضافة جدول مقارنة مع الأعمال المنشورة داخل النوتبوك.
- إضافة جدول يوضح الإسهام البحثي الحقيقي وكيف يعالج كل ملاحظة.
- إعادة صياغة الـ contribution بحيث لا تعتمد على multiple datasets فقط.
- نماذج boosting قوية مثل CatBoost و XGBoost و LightGBM.
- نماذج هجينة تشمل Soft Voting و Stacking.
- تفسير قرارات النموذج باستخدام SHAP.
- تحليل اختيار الخصائص باستخدام ANOVA و Mutual Information.
- إضافة Feature Tokenizer Transformer كنموذج deep tabular learning.
- تقييم باستخدام repeated cross-validation واختبار holdout.
- مقارنة منظمة مع أعمال منشورة مع توضيح حدود المقارنة.

4. النتائج الأساسية

Tuned CatBoostClassifier	94.26%	94.86%	94.56%	96.78%
Tuned Soft Voting Hybrid	94.17%	95.23%	94.52%	97.21%
Tuned Stacking Hybrid - Holdout	92.86%	91.27%	93.12%	97.40%

5. Feature Selection و FT-Transformer

95.14%	90.24%	90.56%	Mutual Information SelectKBest + Tuned XGB
92.80%	92.06%	88.24%	Feature Tokenizer Transformer

ظل أقل من نماذج Feature Tokenizer Transformer كان مفيدا كتحليل بحثي لكنه لم يتفوق على الإطار الهجين الكامل. أما Feature Selection والهجين، وهو أمر متوقع مع البيانات الطبية الجدولية محدودة الحجم boosting فتمت إضافته كخط أساس حديث للتعلم العميق على البيانات الجدولية، لكنه

6. المقارنة مع الأعمال المنشورة

Same family of heart-disease benchmark; protocol differs	0.92	91%	Stacking ensemble	HDDC / D1	Ensemble learning with explainable AI, Scientific Reports 2025
Same family of heart-disease benchmark; protocol differs	0.97	98%	Stacking ensemble	UHDD / D2	Ensemble learning with explainable AI, Scientific Reports 2025
Dataset overlaps with UCI Cleveland; protocol differs	Not reported in Table 5	98.40%	Bayesian-optimized XGBoost + SHAP	Cleveland	Optimized Ensemble Learning with XAI, Information 2024
Different dataset; indirect comparison only	Not reported in Table 6	95.90%	Bayesian-optimized XGBoost + SHAP	Framingham	Optimized Ensemble Learning with XAI, Information 2024
Our reproducible repeated-CV result	0.9678	94.26%	Tuned CatBoostClassifier	OpenML Heart 1190	This work
Our reproducible repeated-CV hybrid result	0.9721	94.17%	Tuned Soft Voting Hybrid	OpenML Heart 1190	This work
Our deep tabular baseline	0.9280	88.24%	Feature Tokenizer Transformer	OpenML Heart 1190 + FT-Transformer	This work

نتائجنا المتولدة من النوتبوك. المقارنة المباشرة لا تكون صحيحة إلا عند استخدام نفس Dataset ونفس preprocessing ونفس evaluation protocol. تم فصل نتائج الأعمال المنشورة عن

7. الإسهام البحثي النهائي

الذي يجمع بين tuned ensemble learning، النماذج الهجينة، قابلية التفسير باستخدام SHAP، تحليل الخصائص، ونموذج FT-Transformer. فقط. استخدام أكثر من مصدر بيانات هو validation لإثبات الثبات وقابلية التعميم. الإسهام الأساسي هو Unified Explainable Hybrid Framework الإسهام البحثي لا يتمثل في استخدام أكثر من Dataset

8. الخلاصة

مقارنة منشورة واضحة وتحديد دقيق لل contribution. الشغل الحالي يقدم إطارا قابلا للتفسير والتكرار، وليس مجرد تجربة نماذج على Dataset واحدة. من الناحية البحثية. النتائج الأساسية وصلت إلى حوالي 94% Accuracy وأكثر من 97% ROC-AUC على OpenML Heart 1190، مع وجود أصبح المشروع الآن أكثر قوة وتنظيما